3D CNN Architectures (강원대학교 이홍구)

***본 자료는 논문 게재 이후 공개될 예정이며, 무단 사용 및 배포를 금지합니다.**

(This document contains unpublished data intended for future publication. All rights reserved. Unauthorized use or distribution is strictly prohibited)

선택된 파장에서 3D spatial-spectral patch를 추출하였다. 각 패치는 $H_p \times W_p \times C$ 크기를 가지며, 여기서 $H_p = W_p = 11$ pixels (공간 크기), C는 선택한 파장의 수다. Center pixel은 분류 대상인 target berry pixel이다.

초분광 영상 데이터는 분광 정보 및 각 분광 정보간의 관계를 통해 정성 정량적 분석을 수행할 수 있다. 그러나 기존 2D CNN 구조는 공간적 특징만을 학습하는 한계가 있다. 3D CNN은 파장 축(Spectral axis)을 시간 축(Temporal axis)으로 간주하여 공간-분광 상관관계를 동시에 연산하여 모델을 개발할 수 있다. 따라서 총 6종의 3D CNN 구조를 개발하고 각 모델별 성능, 상용 구조 2개에 3D CNN을 적용한 모델과 성능을 비교하였다. 사용한 상용 구조는 Resnet50과 MobilenetV2다. 본 연구에서 개발한 3D CNN 구조는 Github~~~에 공개하였다. 각 구조별 특징 요약은 Table 1에 제시하였다.

LiteHSres3D Raw는 4개의 3D CNN 레이어를 직렬 연결하고 각 레이어 뒤에 3D max pooling을 적용한 단순 구조의 경량화 모델이다. 채널은 1 → 4 → 8 → 16 → 32로 진행되며, ReLU 활성화 함수와 Global Average Pooling 기반 분류기를 사용한다. LiteHSRes3D_SE는 Squeeze-and-Excitation (SE) block을 각 convolutional layer 뒤에 배치하여 레이어 깊이에 따라 도출된 특징맵의 계층별 중요도를 학습한다. SE block은 GAP → FC(C→C/r) → ReLU → FC(C/r→C) → Sigmoid 구조로 구성되며(r=8), 파라미터 증가분은 0.0003M이다. C는 입력 채널이며, r은 reduction ratio(본 연구에서는 8로 설정함)이다. 이를 통해 SE에 따른 성능 변화 및 2D CNN 구조에서 VGG와 같은 plain architecture 설계 방향이 초분광 영상 데이터 및 3D CNN에서 효과적일 수 있는지 평가하였다.

ScalableHSRes3D는 width multiplier와 residual learning을 결합한 적응형 아키텍처이다. 4개 stage의 residual block으로 구성되어 있으며, width multiplier w를 5수준(0.25, 0.5, 1.0, 1.5, 2.0)으로 선택할 수 있다. Base channel은 $\max(8, [32 \times w])$로 결정되며, stride pattern은 모든 width에서 (1,2,2) → (2,2,2) → (2,2,2) → (1,2,2)로 동일하게 유지된다. 이는 spectral dimension 보존과 spatial dimension 감소의 균형을 맞추기 위한 설계이다. 각 stage는 2개의 residual block으로 구성되며, Batch Normalization과 SiLU 활성화 함수를 사용한다. 본 실험에서는 ScalableHSRes3D 0.5 (1.8M parameters, 채널: 16→32→64→128)와 ScalableHSRes3D 1.5 (16.2M parameters, 채널: 48→96→192→384)를 사용하였다. ScalableHSRes3D 0.5는 MobileNetV2-3D(2.36M)와 LiteHSRes3D(0.019M) 사이의 중간 용량으로 residual learning의 효과를 평가하며, ScalableHSRes3D 1.5는 ResNet3D-50(25.1M)보다 작은 용량이지만 spectral dimension 보존 구조를 통해 초분광 영상에 특화된 효율적인 성능이 나타날 수 있는지 평가하였다.

HSRes3D_Attention_SE는 deep residual backbone(512 channels)에 Squeeze-and-Excitation (SE) block을 결합한 고용량 모델이다. Spectral stream은 초기 Conv3d(1→32)를 거쳐 3개의 ResidualBlock3D를 통해 32→64→128→256으로 진행되며, stride pattern은 (1,2,2) → (2,2,2) → (1,2,2)를 따른다. Stride의 각 원소는 순서대로 (spectral, height, width) 차원의 downsampling 비율을 의미한다. Fusion module에서 Conv3d(256→512, 1×1×1)를 거쳐 512-channel feature를 생성한 후 SE block을 적용한다. 이 SE block은 GAP → FC(C→C/r) → ReLU → FC(C/r→C) → Sigmoid 구조로, C=512, r=16(reduction ratio)을 사용하여 FC(512→32) → ReLU → FC(32→512) → Sigmoid로 구성되며, 약 32K parameters, 0.8M FLOPs를 가진다. Deep layers는 Layer4(ResBlock 512→512, stride=(2,2,2))와 Layer5(ResBlock 512→512, stride=1)로 구성되며, 최종 분류기는 GAP → FC(512→256) → SiLU → Dropout(0.5) → FC(256→3)이다. 고용량 모델에서 SE block을 통한 채널별 중요도 학습이 효과적인지 검증하고자 하였다.

HSRes3D_Attention_CBAM는 HSRes3D_Attention_SE와 동일한 deep residual backbone을 사용하되, SE 대신 Convolutional Block Attention Module (CBAM)을 적용한다. CBAM은 두 단계의 attention을 순차적으로 적용한다. 먼저 Channel attention - GAP(Global Average Pooling)와 GMP(Global Max Pooling)를 병렬로 수행한 후 shared MLP(Multi-Layer Perceptron)를 거쳐 채널별 중요도를 계산한다. 이후 Spatial attention - channel 차원에 대해 average pooling과 max pooling을 수행한 후 7×7 convolution과 sigmoid를 거쳐 공간적 중요도를 계산한다. 따라서 CBAM은 각 Channel의 Spatial에 대해 주목할 지점을 동시에 학습한다. 이와 같은 구조가 초분광 영상의 복잡한 분광-공간 패턴을 감지할 수 있는지 평가하였다.

Resnet50-3D는 He et al.(2016)이 제안한 ResNet-50을 3D CNN으로 보완한 구조로 Residual learning, skip connection, 50 layers를 가졌다. MobilnetV2-3D는 Howard et al.(2018)이 제안한 MobileNetV2를 3D로 변형한 것으로 Depthwise separable convolution, inverted residual structure를 통해 연산 최적화 및 정보 손실을 방지하였다.

Table 1. Overview of 3D CNN Model Architectures

Model Name	Number of Parameters (M)	Architecture
HSres3D Attention SE	32.4823	Deep ResNet backbone (512 ch) Spectral-Spatial fusion SE block (r=16)
HSres3D Attention CBAM	32.4830	Deep ResNet backbone (512 ch) Spectral-Spatial fusion CBAM (channel+spatial)
ScalableHSRes3D 0.5	1.7985	4-stage ResNet, w=0.5 Channels: 16→32→64→128 Spectral dimension preservation
ScalableHSRes3D 1.5	16.1799	4-stage ResNet, w=1.5 Channels: 48→96→192→384 Spectral dimension preservation
LiteHSRes3D	0.0190	4-layer plain CNN Channels: 1→4→8→16→32 MaxPool3D, ReLU, GAP
LiteHSRes3D SE	0.0193	LiteHSRes3D + SE blocks (r=8) Layer-wise channel attention
ResNet3D-50	46.1612	Standard 3D ResNet-5050 layers, skip connections
MobileNetV2-3D	2.3561	Depthwise separable convolution Inverted residual structureLinear bottleneck